

Deck OEM

Guía de presentación

Acompaña a `oem-slides.pdf` (17 diapositivas, 2 de reserva)

Antes de empezar: la postura

Tu ventaja es que **no vienes a vender IA**. Vienes a contar que la mediste y que casi todo se cayó. Eso desarma al escéptico en el primer minuto, y a partir de ahí te escucha.

Regla de oro: cada vez que digas algo bueno de la IA, di antes el número que lo limita. Nunca al revés.

Tres cosas que NO debes decir:

- “La IA revoluciona el mantenimiento” — pierdes la sala.
- “Nuestro modelo aprende patrones complejos” — suena a folleto.
- Cualquier cifra sin decir contra qué se compara.

Arranque sugerido:

Monté un banco de pruebas para medir si lo que se publica sobre IA en performance se sostiene. Te adelanto el resultado: la mayoría no. Incluido lo mío. Lo que sí queda es pequeño y, curiosamente, no es software.

El texto sangrado es lo que se dice en voz alta; lo que aparece *[así]* son acotaciones, no se pronuncian.

Diapositiva 1 Portada

Léela y pasa. No te detengas.

Diapositiva 2 Start from the skeptical position

La pregunta era simple: ¿la IA gana al método clásico de análisis de gas path, o no? La trampa habitual es comparar una IA bien ajustada contra un método clásico mal ajustado. Aquí les di a los dos el mismo dato, la misma métrica y el mismo presupuesto de ajuste. Y escribí las hipótesis **antes** de correr nada, para no poder cambiarlas después.

[señala la columna derecha] Ahí tienes lo que salió. Un paper publicado cuyo titular resulta ser ruido. Dos titulares míos que se caen a la tercera parte. Y la tarea donde más se vende la IA acaba en empate.

Idea en una frase: no vengo a convencerte, vengo a enseñarte una auditoría.

Diapositiva 3 The rig, in one slide

Construí un motor virtual del CFM56-7B calibrado contra datos de certificación públicos, y con él una flota de cien motores que viven hasta que salen de ala. La clave es esta: **de cada motor sé la verdad**. Sé exactamente cuánto se ha degradado cada componente en cada vuelo.

Eso con datos reales no lo puedes hacer. Con datos reales solo puedes comparar una estimación contra otra estimación. Aquí puedo preguntar lo que de verdad importa: ¿el diagnóstico **acertó**?

[si pregunta “¿y eso es realista?”]

El modelo está anclado a medidas de certificación reales que nunca usé para ajustarlo. Los números absolutos no los defiendo. Lo que se transfiere son los órdenes de magnitud y quién gana a quién, que es de lo que va todo esto.

Diapositiva 4 A peer-reviewed deep-learning result, replicated exactly

[esta es la diapositiva importante; tómate tiempo]

Cogí un paper de 2026, publicado en Springer, revisado por pares. Dice que una red neuronal concreta es la mejor de quince arquitecturas para predecir vida remanente. Lo reimplementé exactamente como está escrito.

Primero, lo justo: **replica**. Me sale **14,56** donde ellos publican **14,12**. No estoy montando un hombre de paja.

Ahora el problema. Ellos ordenan quince arquitecturas con diferencias de entre **0,12 y 0,60**. Pero si entrenas **el mismo modelo dos veces**, cambiando solo el número aleatorio de arranque, el resultado se mueve **2,94**. La diferencia entre modelos es cinco veces más pequeña que el ruido de repetir el mismo modelo. Ese ranking no mide nada. Y ellos publican una sola corrida por modelo.

Y hay algo peor *[señala los puntos rojos]*: en **cinco de diez** corridas el modelo no llega a entrenar. Se queda prediciendo cero. Y la causa está en sus propias tablas: una configuración que, si el modelo se atasca al principio, no puede recuperarse.

[analogía, si hace falta]

Es como cronometrar quince motores en banco, con diferencias de una décima entre ellos, cuando repetir el ensayo del mismo motor te da tres décimas de dispersión.

Diapositiva 5 The evaluation question to ask anyone

De todo esto, si te llevas una sola cosa, que sea esta pregunta: **¿cuál es la dispersión entre repeticiones?** Antes de mirar el titular.

Sirve para un proveedor que te enseña un piloto. Sirve para un equipo interno. Y sirve para mí — de hecho me la apliqué, y es la siguiente diapositiva.

Idea en una frase: un ranking dentro del ruido no es un resultado.

Diapositiva 6 We applied it to our own claims, and both shrank

Me apliqué el mismo criterio y perdí dos titulares.

El primero: yo decía que la IA daba intervalos de incertidumbre **seis veces** más estrechos. Falso tal como estaba dicho. Mi intervalo estaba *calibrado* — ajustado para que cuando digo noventa por ciento, sea de verdad noventa. El del método clásico no lo estaba, y por eso salía anchísimo. Calibras los dos igual y la ventaja se queda en **1,34**. Tres cuartas partes de aquel seis era la calibración, no el modelo. Y la calibración es una técnica que el lado clásico puede coger gratis.

El segundo: “la IA predice la vida remanente entre 2,3 y 4,4 veces mejor”. Cierto, pero solo contra la extrapolación lineal que se usa hoy en operación. Contra un método clásico bueno es **1,34** veces al noventa por ciento de la vida, y **empate** al setenta.

Idea en una frase: cuando la línea base es competente, la ventaja es del 30 %, no de varias veces.

Diapositiva 7 Where AI lost outright

Aquí la IA no gana: pierde el empate. Distinguir entre averías parecidas de gas path: **31 %** el método clásico, **31 %** la IA. Idéntico.

Y esto no es que el algoritmo sea malo. Es que **la información no está en el dato**. Tienes tres medidas de cabina útiles y diez parámetros de salud que estimar. Es como pedirme tres números que sumen diez: hay infinitas respuestas y ninguna manera de elegir. Encima, dos averías distintas dejan huellas separadas **1,3 grados**: casi la misma firma.

Lo comprobé por cuatro caminos independientes. Reduje a la mitad el ruido de todos los sensores: no cambia. Metí un “sensor virtual”, que es lo que venden algunos proveedores: **cero, exactamente cero**. Barrí todo el envoltorio de operación: sigue en **1,38 grados**. Y ningún método aprendido lo movió.

[remate, pausa antes]

Ningún algoritmo arregla que falte información.

Diapositiva 8 And most prognostic error is not a method gap

Y una última mala noticia, que en realidad es dinero. El **87 %** de la incertidumbre en vida remanente a mitad de vida es **irreducible**. Dos motores que miden exactamente igual fallan de verdad con cientos de ciclos de diferencia. No es que no sepamos medirlo: es que el futuro no está escrito en la medida de hoy.

Esto lo puedo afirmar porque conozco la verdad de cada motor. Y lo que significa para presupuesto es directo: si financias un algoritmo mejor para predecir a mitad de vida, estás persiguiendo ruido. Al final de la vida sí se abre un margen de **cuatro veces**: ahí sí paga.

Diapositiva 9–10 An instrumentation design tool / Why this one is ours to act on

[cambio de tono: llevas media presentación diciendo que no; ahora el sí]

Lo más sólido que salió de todo esto **no es IA**. Es teoría de estimación clásica aplicada a través del modelo del motor.

La idea: para un motor y sus condiciones reales de vuelo, puedo calcular cuánta información sobre cada componente llega de verdad a los sensores. Y de ahí sale un límite: esto lo puedes saber, esto no lo puede saber *nadie* con esos sensores.

Mira la tabla. Si añades sondas de estación, la eficiencia del compresor de alta pasa a estimarse **45 veces** mejor, y distinguir las averías confusas pasa de **0,15 a 0,92**. Si en cambio reduces el ruido de las sondas que ya tienes: no cambia nada. Si compras software con “sensores virtuales”: no cambia nada.

Y aquí está la consecuencia para nosotros: cualquier servicio de EHM montado **solo sobre datos de cabina** tiene un techo que ningún roadmap de software levanta. La salida es instrumentación. Y la instrumentación la decidimos nosotros, no el cliente.

Idea en una frase: esto pone precio a una decisión de hardware antes de comprometer el hardware.

Diapositiva 11 The one AI result that held up

Y ahora sí, lo único de IA que aguantó, y es más estrecho y más útil que lo que se suele contar.

Meter física dentro del modelo — darle al aprendiz la estimación del estado del motor — **empeora** la predicción de vida remanente. Lo comprobé dos veces y las dos falló. Pero esa misma inyección **mejora mucho** decir qué mecanismo se está comiendo el motor.

Y lo monté con un brazo de control, para que no me pudiera engañar a mí mismo: si el control también hubiera ganado, entonces la mejora sería solo “más datos de entrada”.

La explicación es mecánica y tiene sentido: la vida remanente ya va en el margen de EGT que el modelo está viendo, así que el estado físico no le añade nada. Pero *qué módulo* se está degradando es justo lo que ese estado codifica.

Conclusión: “physics-informed” no es ni magia ni humo. **Depende de la tarea**. Y ahora sé de cuál.

Diapositiva 12 What this is, and what it is not

[dila entera, sin acelerar: es la que te da credibilidad]

Qué **no** es esto. No es un producto. No es una herramienta validada para uso operativo. Y los números absolutos no los defiende: la flota es sintética y el modelo está calibrado contra datos públicos, no contra nuestro banco.

Qué **sí** es: un método reutilizable para decidir qué afirmaciones sobre IA en performance financiamos y cuáles rechazamos. Con la disciplina que hace que las respuestas valgan algo — hipótesis congeladas antes de correr, mismo presupuesto de ajuste para los dos lados, los resultados negativos con el mismo peso que los positivos, y ninguna cifra escrita a mano: todas salen del código.

Diapositiva 13 Proposed next step

La propuesta es una sola: repetir el análisis de instrumentación sobre **nuestros** modelos de motor y sobre las configuraciones de sensores que estemos considerando.

No necesita IA. No necesita recoger datos nuevos. Y responde a una pregunta que ya estamos pagando por responder de otra manera.

[y cállate: deja que hable él]

Diapositiva 14–15 Reserva

No las pases salvo que pregunte. Están para:

- **Disciplina de método** — si pregunta “¿y cómo sé que no te has engañado?”
- **El muro es instantáneo** — si pregunta “¿entonces no se puede diagnosticar nada?”

Objeciones probables, y qué contestar

“Esto es todo simulado, no me sirve.”

Correcto, y por eso no defiende ningún número absoluto. Lo que se transfiere es la geometría: cuántas incógnitas hay contra cuántas medidas. Eso es igual en nuestro motor real, y es lo que manda. Además, el análisis de instrumentación corre sobre nuestros modelos, donde es más fuerte que aquí.

“La IA es humo.”

En tres de las cuatro tareas que medí, te doy la razón con números. En la cuarta hay un 30 % de mejora, que es real y es pequeño. Lo que te propongo no depende de que la IA funcione.

“¿Cuánto ha costado esto?”

Corre entero en un portátil en minutos. Y todo viene de datos públicos de certificación, así que no hay problema de propiedad intelectual para circularlo internamente.

“¿Por qué no lo ha hecho ya un proveedor?”

Porque hace falta conocer la verdad del motor para validarlo, y eso solo lo tienes en simulación. Un estudio con datos reales no puede comprobar si su propia estimación de incertidumbre es honesta. Nosotros sí.

“¿Y si el proveedor X dice que su modelo da un 95 %?”

Primera pregunta: ¿contra qué línea base, y estaba ajustada igual? Segunda: ¿cuál es la dispersión entre repeticiones? Con esas dos preguntas se cae la mayoría.

Si solo tienes cinco minutos

Diapositivas 4, 6, 7, 9 y 13, en ese orden.

Un paper publicado que no se sostiene → mis propios números corregidos → dónde la IA pierde y por qué → lo que sí sirve, que es instrumentación → la propuesta.