

EHMbrAIn

Guión de la presentación

Acompaña a `EHMbrAIn-slides.pdf` (44 páginas, 31 diapositivas numeradas)

Cómo usar este guión

Los números de diapositiva son **páginas del PDF**. El texto sangrado es lo que se dice en voz alta; lo que aparece *[así]* son acotaciones, no se pronuncian.

Las diapositivas están en inglés y sus títulos se citan aquí en inglés para poder localizarlas de un vistazo. Los términos técnicos que aparecen en pantalla se mantienen en inglés la primera vez que salen, con la traducción al lado.

Bloque	Diapositivas	Tiempo
Apertura	1–2	2 min
1. El problema	3–6	4 min
2. La física, y por qué el diagnóstico es difícil	7–11	6 min
3. El banco de pruebas	12–16	5 min
4. Qué entrega el GPA clásico	17–21	5 min
5. El concurso pre-registrado	22–28	7 min
6. Más allá del muro	29–35	7 min
7. Qué llevarse	36–40	4 min
Total	40 min + 10 de preguntas	

Si vas justo de tiempo, recorta en este orden: diapositiva 20 (detectabilidad), 28 (sim-to-real), 33 (piso pronóstico), 35 (economía). **No recortes nunca** la 10, la 11, la 25 ni la 31: el muro de observabilidad es la espina dorsal del argumento y sin esas cuatro la conclusión de compra no se sostiene.

Apertura — diapositivas 1–2

2 min

Diapositiva 1 Portada

Este es un estudio sobre una comparación que la literatura lleva tiempo haciendo mal. El aprendizaje automático se aplica ya de forma rutinaria a la monitorización de salud de motores, y de forma igual de rutinaria se publica que gana a los métodos clásicos. Lo que voy a defender es que casi ninguna de esas comparaciones es justa; que cuando haces una que sí lo es, la respuesta se parte de una manera interesante; y que esa partición te dice exactamente dónde hay que gastar el dinero.

Diapositiva 2 Where this talk goes

Voy a trabajar en dos niveles todo el rato. Cada diapositiva abre con la afirmación en una línea y debajo enseña el mecanismo que la produce. Si solo sigues las líneas de arriba te llevas el argumento completo; el resto está ahí para quien quiera comprobarlo.

[No leas el índice en voz alta. Señálalo, una frase, y sigue.]

1. El problema — diapositivas 3–6

4 min

Diapositiva 4 An engine degrades where nobody can look

Esta es la situación física. Un turbofán comercial se queda atornillado a un ala durante años. En ese tiempo el polvo y la contaminación ensucian los álabes del compresor, la sección caliente sufre fluencia y se oxida, las holguras de punta de álabe se abren, los sellos se desgastan. Nada de eso se ve. Nadie abre el motor para mirar.

Lo que la aerolínea recibe a cambio es esto: un puñado de números por vuelo. Velocidades de eje, temperatura de gases de escape, consumo de combustible. Esa es toda la ventana.

[señala la figura] Y este es el agregado que un operador vigila de verdad: el margen de temperatura de gases de escape, la distancia al límite certificado. Los dientes de sierra son lavados de compresor. Cuando llega a cero el motor sale del ala. Una visita a taller cuesta millones de dólares; una retirada no programada le destroza la programación a una flota entera durante días.

Diapositiva 5 Two schools, and a broken comparison

Hay dos familias de métodos que interpretan esa ventana.

La clásica viene de los años setenta: el *gas path analysis*, el análisis del camino de gases. Construyes un modelo termodinámico del motor y lo inviertes: a partir de los síntomas, trabajas hacia atrás hasta saber qué componente se ha degradado y cuánto. Alrededor de ese núcleo la industria construyó una caja de herramientas madura: modelos de referencia, suavizado de tendencias, filtros de Kalman, reglas expertas.

La segunda es el aprendizaje automático, sobre todo en la última década, sobre todo en predicción de vida remanente, y sobre todo sobre bancos de pruebas sintéticos.

[baja el ritmo aquí: esta es la afirmación que motiva toda la charla] Y aquí está el problema. A la IA casi nunca se la compara contra un pipeline tradicional implementado con el mismo cuidado: mismos datos, mismas métricas, mismo esfuerzo de ajuste. Lo que el campo tiene es un flujo continuo de comparaciones contra hombres de paja. Lo cual significa que en realidad no sabemos qué aporta la IA, bajo qué condiciones, ni a qué coste.

Diapositiva 6 What this project builds

Así que este proyecto construye la comparación justa. Tres piezas.

Un gemelo termodinámico de un motor concreto — el CFM56-7B, el que llevan la mayoría

de los 737NG — construido únicamente a partir de datos públicos certificados. Cien motores virtuales llevados hasta el fallo, en el formato de datos exacto que recibe una aerolínea. Y las dos familias de métodos sobre datos idénticos, métricas idénticas, particiones idénticas y presupuesto de ajuste idéntico, juzgadas bajo un protocolo congelado antes de ver ningún resultado.

[la idea clave de la charla: aterrizala] La razón de hacerlo sintético está abajo en la diapositiva. En una flota real puedes preguntar «¿predijo bien el método?». Lo que no puedes preguntar es «¿le echó la culpa al componente correcto?», porque nadie conoce el estado interno verdadero de un motor montado en un ala. Con verdad-terreno sintética sí puedes. Y la atribución es precisamente donde el GPA clásico es más débil y donde la IA es menos transparente — así que es la pregunta que justifica construir un banco de pruebas entero.

2. La física — diapositivas 7–11

6 min

[Este es el cimientito de bajo nivel. Si el público es aeronáutico, ve rápido. Si es de aprendizaje automático, esta es la parte que más necesitan.]

Diapositiva 8 The machine, in one picture

Muy brevemente, la máquina. El aire entra por el fan. La mayor parte rodea el núcleo y produce la mayor parte del empuje. El resto se comprime, se quema, y se expande a través de dos turbinas que mueven los compresores.

El hecho estructural importante es que hay dos ejes mecánicamente independientes, dos *spools*. El de baja presión: fan y booster movidos por la turbina de baja, girando a una velocidad que se llama N1. El de alta presión: compresor y turbina de alta, a N2.

Los números de abajo son numeración de estaciones y van a reaparecer en diapositivas posteriores. Y la frase del pie es la restricción bajo la que vive toda esta charla: la aerolínea recibe cuatro canales. N1, N2, temperatura de escape y consumo de combustible. Algunas flotas compran un paquete opcional con presiones y temperaturas dentro del núcleo. La mayoría no.

Diapositiva 9 Gas path analysis: the model to invert

Ahora la matemática, y es corta.

Describimos la condición interna del motor con dos números por turbomáquina. El rendimiento isentrópico — cuánto del trabajo ideal consigue de verdad; la suciedad y el desgaste lo reducen. Y la capacidad de paso — cuánto aire traga; el ensuciamiento cierra un compresor, la erosión abre una turbina. Cinco turbomáquinas, así que diez números. Ese vector es lo que mantenimiento quiere saber, y no es medible.

Lo que sí es medible son las desviaciones de los canales medidos respecto de lo que leería un motor sano en la misma condición de operación. Para las desviaciones pequeñas del desgaste en servicio la relación es lineal: desviaciones medidas igual a una matriz de influencia por el vector de salud, más sesgo de sensor, más ruido.

[pausa] Y ahora mira la forma de ese problema. Diez incógnitas. Tres medidas utilizables —

N1 no cuenta, es el parámetro de empuje comandado, no un síntoma. Así que la matriz tiene rango tres. Hay infinitos estados de salud compatibles con cualquier medida. La respuesta clásica regulariza: penaliza desviaciones implausiblemente grandes y elige una solución. Eso funciona, y te cuesta precisión de una forma que vamos a medir exactamente.

Diapositiva 10 Smearing: how a diagnosis flips to the wrong component

Esto es lo que hace ese mal condicionamiento en la práctica, en un problema lo bastante pequeño como para comprobarlo a mano.

Dos parámetros de salud, dos medidas. La verdad es una pérdida del uno por ciento de rendimiento en el compresor de alta. Metes las medidas exactas en la inversión y lo recuperas exactamente.

Ahora perturba una medida una décima de por ciento — una desviación típica de ruido de sensor. *[señala]* La respuesta pasa a ser: compresor sano, turbina degradada un uno por ciento. El diagnóstico ha saltado al componente equivocado por completo.

El dibujo de la derecha explica por qué. Cada fallo produce su propio patrón de movimiento de los indicadores; piénsalo como una flecha en el espacio de medidas. Diagnosticar es preguntar a lo largo de qué flecha apunta la lectura observada. Cuando dos flechas son casi paralelas, un empujón del tamaño del ruido mueve la lectura de una a la otra. Esto se llama *smearing*, embadurnamiento, y no hay nada mal en el álgebra. Sencillamente, la información no está en las medidas.

Diapositiva 11 This engine's actual geometry

Eso era un juguete. Este es el motor real.

Con el conjunto de sensores de cabina, el ángulo más pequeño entre dos firmas de fallo en este motor es de **1,3 grados** — entre el rendimiento del compresor de alta y el rendimiento de la turbina de alta. Siete pares quedan por debajo de quince grados, que es más o menos donde el ruido de sensor funde dos fallos en uno. Rango tres para diez incógnitas.

Añade las cuatro sondas de estación y el rango sube a siete y el peor ángulo se multiplica por cinco.

[esta es la afirmación portante de la charla: dila despacio] Y repetimos esto sobre una rejilla de seis puntos que cubre la envolvente de vuelo. La estructura apenas se mueve: entre 1,2 y 1,4 grados en todas partes. O sea que la ceguera no es una propiedad de una condición de vuelo concreta de la que puedas escapar midiendo en otro sitio. Es intrínseca al conjunto de sensores. Quedaos con eso, porque todo lo que viene en la segunda mitad de la charla es una consecuencia.

3. El banco de pruebas — diapositivas 12–16

5 min

Diapositiva 13 The twin: certified data in, predictions out

El gemelo está construido en pyCycle, la librería abierta de modelado de ciclo de la NASA, transformando un ejemplo validado hacia este motor: como máximo tres parámetros por paso, exigiendo convergencia en cada paso. Suena quisquilloso; es la diferencia entre tener un modelo y pasar tres semanas depurando un solver de Newton.

La calibración es la parte que merece atención. Usa exclusivamente datos medidos certificados: la hoja de certificado de tipo, y la base de datos de emisiones de la OACI, que publica algo silenciosamente valioso — consumos de combustible **medidos** en banco a nivel del mar, en cuatro regímenes de empuje, para esta variante exacta de motor, gratis.

Y resolvemos los puntos de anclaje con el empuje impuesto. Así que el consumo del modelo es una **predicción**, confrontada contra una medida a la que nunca se ajustó. Ese es el examen honesto, y sale dentro del uno y medio al tres por ciento en despegue, ascenso y aproximación. El consumo específico en crucero cae dentro del dos por ciento del valor publicado sin haber sido nunca un objetivo.

Diapositiva 14 The fleet: six mechanisms, one hundred lives

A partir de ese gemelo generamos cien motores viviendo vidas completas. Seis mecanismos de degradación, cada uno una función en forma cerrada del ciclo de vuelo, con magnitudes tomadas de la literatura de degradación de turbinas de gas.

[recorre los paneles] Ensuciamiento saturando hacia una asíntota con recuperaciones por lavado. Erosión lineal. Holgura de punta que se abre rápido y luego despacio. Sección caliente acelerando al final — rendimiento abajo, capacidad de paso arriba: ese par es la firma de una tobera de turbina erosionada. Daño por objeto extraño como escalones de Poisson. Y episodios de fallo agudo discretos.

El detalle que importa después: la contribución de cada mecanismo se guarda por separado. Así que la flota no registra solo cuánto está degradado un motor, sino **por qué**.

Diapositiva 15 Making the benchmark hard on purpose

Ahora bien: la enfermedad más común de un dataset sintético es ser accidentalmente fácil, y un banco de pruebas que halaga a tu método no vale nada. Así que pusimos un umbral por adelantado: un clasificador deliberadamente débil — una regresión logística simple sobre canales crudos — tiene que **fallar** en la tarea de aislamiento, por debajo del sesenta por ciento.

Primera pasada: sacó casi un ochenta y dos por ciento. El umbral falló.

[este es un momento de credibilidad: no lo corras] Diagnosticamos por qué. Nuestras etiquetas de fallo eran el mecanismo crónico dominante, y los mecanismos crónicos co-evolucionan con la edad en todos los motores. Así que la etiqueta era un proxy de la edad, y los niveles crudos de los canales codifican la edad directamente. La tarea que habíamos definido no era aislamiento de fallos en absoluto.

Había dos respuestas posibles: relajar el umbral, o arreglar el diseño. Rediseñamos el dataset — episodios de fallo discretos de un solo parámetro, elegidos entre los pares confundibles — y pasó con un cincuenta y cuatro por ciento. Después, en una versión posterior de la flota, el umbral mordió **otra vez** con un sesenta y dos por ciento, y escalamos las magnitudes de

fallo hacia abajo hasta que pasó.

Los dos fallos están en el informe con todo detalle, porque un umbral que no puede fallar no certifica nada.

Diapositiva 16 Four safeguards, fixed before any contestant ran

Cuatro salvaguardas, todas fijadas antes de que corriera ningún método.

Pre-registro: hipótesis, umbrales, particiones con hashes de fichero, tests estadísticos, todo congelado bajo una etiqueta de git antes de la pasada confirmatoria. Prestado de los ensayos clínicos: declaras qué te convencería antes de mirar la respuesta.

Presupuesto de ajuste simétrico: cincuenta pruebas de búsqueda automática para cada familia. Esta importa más de lo que parece. Cualquier asimetría de esfuerzo convierte silenciosamente una comparación de métodos en una comparación de esfuerzo, y esa es exactamente la enfermedad de la literatura.

Partición por motor, nunca por vuelo: los vuelos de un mismo motor son casi duplicados, y partir por vuelo permite que un modelo memorice motores concretos.

Y una línea base de verdad fuerte: el pipeline tradicional construido con forma industrial, cada regla experta justificada.

El bloque de abajo es la disciplina que hace creíble todo lo demás. Los números existen en dos castas y nunca se mezclan. Exploratorios, producidos mientras construyes. Confirmatorios, producidos una sola vez, después del congelado, sobre datos tocados exactamente una vez. Solo los segundos sostienen un veredicto.

4. Qué entrega el GPA clásico — diapositivas 17–21

5 min

[Esta sección es nueva respecto a cómo se suele presentar este trabajo, y es el suelo cuantitativo de todo lo que viene después. No te saltes la 19.]

Diapositiva 18 The experiment: honest forward, classical inverse

Antes de comparar nada con nada, una pregunta que en esta literatura nadie parece responder: ¿qué entrega de verdad el método de libro de texto sobre este motor?

El diseño importa. Para la dirección directa — la que hace de motor — usamos un gemelo neuronal **no lineal** del modelo termodinámico, con toda la curvatura de la física. Para la inversa — la que hace de sistema de monitorización — usamos los mínimos cuadrados regularizados **lineales** sobre la matriz de influencia. Dos instrumentos distintos a propósito: invertir la misma matriz que generó los datos sería circular y exacto por construcción, y no nos diría nada.

Aquí va una ejecución. El compresor pierde un uno por ciento de rendimiento. La cabina ve el consumo subir medio punto, la temperatura subir medio punto, la velocidad del núcleo bajar una décima. Inviertes eso y recuperas **un cuarto** del fallo. Repítelo quinientas veces con ruido de sensor fresco y el método nombra el componente correcto el **veintidós por ciento** de las veces. Su respuesta equivocada favorita es la turbina.

Diapositiva 19 What the inversion gives back

Ahora sistemáticamente, un fallo cada vez, los dos conjuntos de sensores.

Panel izquierdo, la magnitud que vuelve. Con el conjunto de cabina, entre un dos y un setenta y seis por ciento según el parámetro. Con las sondas de estación, entre treinta y noventa.

El panel derecho es el que hay que mirar. El índice de *smearing*: la parte de la magnitud diagnosticada que aterriza sobre componentes que en realidad están sanos. Mediana **0,85**. Seis séptimas partes de lo que el método reporta se atribuye al sitio equivocado. Y fíjate en que las sondas de estación apenas lo mejoran: más sensores te compran magnitud, no limpieza, porque el estimador sigue repartiendo lo que no puede separar.

El caso extremo merece nombrarse. Capacidad de paso de la turbina de alta: la cabina recupera **un uno coma nueve por ciento** — el fallo es prácticamente invisible — y el conjunto extendido recupera un noventa. Eso es un factor cuarenta y siete comprado con una sonda de presión a la salida del compresor.

Diapositiva 20 How small a fault can be named

[recortable]

Traduciendo eso al número que pediría un operador: ¿cómo de pequeño puede ser un fallo para que este paquete de sensores todavía lo nombre bien nueve de cada diez veces?

Conjunto de cabina: lo consigue para **uno** de los diez parámetros. El conjunto extendido lo consigue para siete, varios por debajo del uno por ciento.

Y los fallos de nuestra flota están entre el 0,3 y el 1,1 por ciento. O sea que la mayoría de los fallos de este banco de pruebas caen por debajo del límite de resolución del conjunto de cabina — lo cual va a explicar, dentro de unos cinco minutos, por qué el concurso de aislamiento acaba como acaba.

Diapositiva 21 A real engine, eight faults at once

Los fallos individuales son el ejercicio de libro. Los motores reales se degradan por todas partes a la vez, así que aquí hay un motor real de la flota al final de su vida, diagnosticado.

En negro, la verdad. El motor está dominado por daño de sección caliente: rendimiento de turbina cuatro puntos abajo, y la capacidad de paso abierta dos coma cuatro.

El diagnóstico de cabina, en rojo, acierta el titular: rendimiento de turbina tres coma tres abajo. Y luego falla justo en la física que lo confirmaría: la apertura de capacidad vuelve como **cero coma seis** en vez de dos coma cuatro. Así que la firma clásica de tobera erosionada sencillamente no es visible en el diagnóstico. El conjunto extendido, en azul, sí la recupera.

[la parte honesta: dila] Y los dos se inventan daño que no existe. La pérdida real de rendimiento del fan es de menos de medio punto; ambos reportan el triple. La capacidad de paso real de la turbina de baja es esencialmente cero; ambos reportan alrededor de menos uno coma tres — equivocados en el signo además de en el tamaño. Una decisión de mantenimiento tomada sobre esos dos números abre un módulo sano.

5. El concurso pre-registrado — diapositivas 22–28

7 min

Diapositiva 23 Five hypotheses, one confirmatory pass

Ahora sí, la comparación. Las dos familias ajustadas bajo el presupuesto congelado de cincuenta pruebas, los veinte motores de test evaluados exactamente una vez, Wilcoxon emparejado por motor, McNemar exacto para los resultados binarios, corrección de Holm entre hipótesis.

Tres confirmadas, dos refutadas. *[deja que lo lean un momento]* Y quiero dejar claro que las dos refutaciones no son fallos del estudio: son dos de sus cuatro resultados más útiles. De hecho las dos refutaciones hicieron más trabajo que las tres confirmaciones: las confirmaciones dijeron más o menos lo que el campo esperaba — el aprendizaje predice mejor la vida, detecta antes, cuantifica mejor la incertidumbre. Son las refutaciones las que cambiaron nuestras recomendaciones. Las voy a tomar en orden.

Diapositiva 24 H1 — the story is the tuning, not the model

Detección primero, y aquí la historia va de método, no de modelos.

Antes del ajuste, nuestro detector de IA sacaba un recall de 0,06 y escribimos en el informe que aquello parecía un problema de diseño, no de umbral. El espacio de búsqueda congelado contenía justamente la palanca que sospechábamos: la longitud de las ventanas de características. Con cincuenta pruebas el optimizador estiró esas ventanas, y el recall pasó de 0,06 a **0,48**, con un retardo mediano de 499 ciclos. Doce veces antes que el detector clásico ajustado, con el mismo número de falsas alarmas.

De aquí salen dos cosas transferibles. La longitud de ventana es la primera perilla de la que vive o muere cualquier detector de cambios. Y — la incómoda — la configuración ajustada del lado tradicional se seleccionó sobre una partición de validación con solo dos motores limpios, y generalizó peor que sus propios valores por defecto sin ajustar. La selección de umbrales sobre muestras limpias pequeñas es frágil para **cualquier** método. Presupuestad motores limpios en consecuencia.

Diapositiva 25 H2 refuted — the wall binds everyone

Aislamiento. Esta es la hipótesis que más esperábamos confirmar, y queda refutada.

Sobre los trece episodios confundibles de test las dos familias empatan exactamente. Treinta y uno por ciento cada una. Y el patrón de desacuerdo es perfectamente simétrico: cuatro episodios que solo acierta la IA, cuatro que solo acierta la regla clásica. Está muy cerca de ser una moneda al aire cuál de las dos se lleva el punto.

[esta es la conclusión central de la charla] Ahora bien, esto lo predijimos antes de que corriera ningún modelo, a partir de la geometría de la matriz de influencia: firmas separadas 1,3 grados en un espacio de medidas de rango tres. Las dos familias están limitadas por la misma información, y ninguna cantidad de modelado recupera información que los sensores nunca capturaron.

Lo cual convierte una pregunta de software en una pregunta de compras. Si el aislamiento de fallos confundibles importa en tu operación, la solución es instrumentación.

Diapositiva 26 H3 and H5 — prognosis is where learning pays

La prognosis es donde el aprendizaje se gana el sueldo, y de forma decisiva.

Error de vida remanente de 858 ciclos al noventa por ciento de la vida, contra 1981 de la extrapolación clásica ajustada. Tamaño de efecto 0,89: coge al azar el error de un motor de cada método y el clásico es mayor alrededor del noventa y cuatro por ciento de las veces.

[di las dos escalas: no cites solo la grande] Y sé honesto sobre contra qué línea base es eso. El factor 2,3 es contra la extrapolación lineal que un operador tiene hoy desplegada. Contra el mejor pronóstico clásico avanzado — basado en similitud, que sí puede seguir la curva — se estrecha a 1,34 veces. Y se estrecha más todavía, porque volvimos atrás y corrimos la comparación en **todas** las fracciones de vida en vez de solo al noventa por ciento. Al setenta por ciento de la vida los dos métodos **empatan**: 1059 ciclos contra 1064, con una p de 0,41. La ventaja del aprendizaje en prognosis no es un desplazamiento uniforme a lo largo de la vida. Es un efecto **de vida tardía**. Y tiene sentido: nuestro propio piso pronóstico dice que a media vida el ochenta y siete por ciento de la dispersión es irreducible. Donde no hay nada que ganar, no gana nadie.

Así que la frase honesta es: compra el horizonte de visita a taller, no la tendencia de media vida.

Pero mira la forma más que el número. *[señala]* Los errores clásicos son anchos y están sesgados hacia el **optimismo**: predice más vida remanente de la que hay, sistemáticamente, que es la dirección peligrosa. Los de la IA son estrechos y casi insesgados. El mecanismo es simple: una recta no puede curvarse para seguir la degradación acelerada de la sección caliente, y un modelo de secuencia aprende esa curvatura de los datos.

Y la declaración de incertidumbre que viene con ello, que es la hipótesis cinco. El intervalo conformal cubre el ochenta y ocho por ciento empíricamente contra un noventa nominal, con más menos dos mil ciclos. La banda clásica sobre-cubre al noventa y ocho por ciento pero mide más menos once mil quinientos. Esa es la diferencia entre una ranura de taller planificable y un encogimiento de hombros.

[la corrección: dila tú, no dejes que la encuentre otro] Pero ese factor seis no es un resultado de IA, y quiero decirlo antes de que nadie lo pregunte. Nuestro lado estaba calibrado con conformal al noventa por ciento. El suyo no estaba calibrado con nada, sobre-cubre, y un intervalo que sobre-cubre es ancho por construcción. La predicción conformal es agnóstica al modelo — el lado clásico puede cogerla y ya está. Así que volvimos atrás y envolvimos el mismo procedimiento conformal alrededor de los tres predictores. A igualdad de cobertura, el intervalo de la IA es **1,34 veces** más estrecho que el del clásico avanzado, y **2,3 veces** más estrecho que la práctica desplegada. No seis. Unas tres cuartas partes de aquel titular eran el método de calibración, no el modelo.

Y la versión práctica de eso, para quien aquí tenga un pronóstico en producción: antes de comprar un modelo, ponle un envoltorio conformal al que ya tienes. Cincuenta líneas de código, sin tocar el modelo, y te llevas la mayor parte de la mejora del intervalo.

Diapositiva 27 H4 refuted — physics features are not free wins

La segunda refutación, y la que más me gustaría que un profesional se llevara.

«Physics-informed» es una etiqueta popular. La implementación obvia es meterle a la red tus estimaciones de estado basadas en física junto con los datos crudos. Pre-registramos la predicción de que eso ayudaría sobre todo cuando los datos escasean.

Empeoró las cosas **en todas las fracciones de datos**, y empeoró más justamente donde predijimos que más ayudaría. El mecanismo se entiende a posteriori: esas estimaciones de estado están fuertemente embadurnadas. Son diez canales ruidosos y mutuamente correlacionados cuyo contenido de información ya está presente en las tres desviaciones a partir de las cuales se calcularon. Con siete motores de entrenamiento, diez dimensiones de entrada extra son varianza pura.

Después reabrimos esto por una segunda vía independiente — otra característica, otra flota, física no lineal — y volvió a quedar refutado. Dos negativos. La inyección de física necesita un canal de información que los datos crudos no tengan; concatenar salidas de un estimador no lo es.

Diapositiva 28 Does the ranking survive outside our own simulator?

[recortable]

La objeción obvia a todo lo anterior es que nosotros construimos el mundo en el que se está puntuando a estos métodos. Así que reejecutamos la pregunta de prognosis sobre C-MAPSS, de la NASA, el banco de pruebas de referencia del campo, en cuya generación no tuvimos ninguna mano.

Misma dirección, magnitud comparable: 14,9 ciclos contra 42,1. El orden no es un artefacto de nuestro simulador.

Una divulgación, a la derecha: nuestro plan nombraba el banco sucesor, más grande, cuya distribución de varios gigabytes rompe la regla de este proyecto de que todo tiene que correr en un ordenador de escritorio. Sustituimos, y lo decimos en el registro de decisiones en lugar de cambiar el plan en silencio.

6. Más allá del muro — diapositivas 29–35

7 min

Diapositiva 30 Can observability be bought without hardware?

El resultado de aislamiento terminaba en «compra sensores», que es una conclusión cara. Así que buscamos salidas más baratas, y encontramos dos.

La matriz de influencia no es una sola matriz: cambia con la condición de vuelo. Así que una ventana de instantáneas ordinarias tomadas en condiciones dispersas es un conjunto de proyecciones distintas del mismo estado de salud, y fusionarlas es un problema de tomografía.

La auditoría dio una respuesta de dos caras. *[señala la figura]* La dispersión gratis — la variación de ambiente y potencia que te sale sin pagar — restaura el rango algebraico inmediatamente, pero los ángulos saturan casi de inmediato. La variación gratuita es real

pero delgada.

Entonces: salida uno. Tratar el **calendario de reportes rutinarios** como una variable de diseño de observabilidad, lo cual, hasta donde sabemos, es un planteamiento nuevo. Añadir un reporte periódico de crucero estabilizado a baja potencia compra un setenta y nueve por ciento más de separabilidad en la ambigüedad de la turbina. El coste es un boletín de procedimiento, no aviónica.

Salida dos. Fusiona la ventana con un modelo aprendido, pero conserva la inversión física. Una red alimentada con las inversiones físicas vuelo a vuelo aísla al 0,65 contra el 0,17 del apilado clásico. La misma red alimentada con secuencias crudas fracasa directamente al 0,12. La división del trabajo es la lección: deja que la física haga la inversión que hace bien, y que la red haga la fusión temporal que hace bien.

Y lo que ningún calendario arregla: el par rendimiento de compresor contra rendimiento de turbina se queda por debajo de 1,8 grados en toda la envolvente. Ese es fundamental.

Diapositiva 31 Only a real sensor breaks the wall

Lo cual plantea la pregunta que te hará un proveedor: ¿y no podemos **predecir** el sensor que falta a partir de los que ya tienes? Tenemos un gemelo calibrado; que calcule una sonda de presión virtual.

Tres condiciones, pre-registradas. Solo cabina: 0,15. Cabina más canales de estación **virtuales**: 0,15, con p igual a uno. Cabina más canales de estación **reales**: **0,92**.

Esto es la desigualdad de procesamiento de datos hecha operación. Una cantidad calculada a partir de los datos de cabina no puede llevar información que los datos de cabina no tuvieran ya, así que no puede separar fallos que la cabina no puede separar. Ningún proveedor de software, por sofisticado que sea, sustituye a la medida que falta.

La nota práctica está abajo, y es una noticia inusualmente buena: los parámetros que rompen el muro ya los mide el ordenador de control del motor. La barrera es registrarlos y bajarlos a tierra, no instalar hardware.

Diapositiva 32 A certificate of what a diagnosis can know

Esta es la parte que más me gustaría que sobreviviera a la charla.

Todo diagnóstico de camino de gases en la industria es una estimación puntual que esconde lo que no puede saber. Entonces: acumula información de Fisher sobre las condiciones que un motor individual voló de verdad, a través del gemelo calibrado. Invierte. Obtienes la cota de Cramér-Rao — la mejor precisión por dirección que **cualquier** estimador insesgado puede alcanzar con los datos de ese motor. Eso es un certificado por motor, resuelto por su historia, de lo que su diagnóstico puede afirmar honestamente.

Análisis de observabilidad de turbinas de gas existen. Lo que nunca ha sido posible es el panel de la derecha: **comprobar que el certificado es honesto**, porque en un motor real el estado verdadero de los componentes es incognoscible.

Aquí sí es cognoscible. La precisión certificada ordena el error real del filtro contra la verdad-terreno con una correlación de 0,70. Las direcciones que el certificado llama identificables

son las que el estimador acierta; las que llama inobservables son donde la estimación no vale nada. Hasta donde sabemos, esa es la primera garantía de identificabilidad validada contra verdad-terreno para diagnóstico de camino de gases — y es una validación que solo un banco de pruebas con verdad sintética puede llevar a cabo.

Diapositiva 33 Is a large RUL error the method's fault, or the future's?

[recortable]

El mismo truco, aplicado al futuro en lugar de al presente.

Antes de financiar un mejor pronóstico, un operador debería preguntarse: ¿mi error es grande porque mi método es débil, o porque el futuro es genuinamente incognoscible a partir de lo que puedo ver hoy? Esas dos cosas tienen remedios opuestos, y confundirlas o desperdicia presupuesto o abandona un objetivo que estaba al alcance.

Así que condicionamos sobre la salud **verdadera** actual de cada motor, buscamos sus vecinos más próximos en el espacio de salud — motores en una condición presente casi idéntica — y medimos la dispersión de sus vidas remanentes verdaderas. Dos motores en el mismo estado que fallan con cientos de ciclos de diferencia difieren por razones que ninguna medida presente contiene. Esa dispersión es un suelo irreducible.

A mitad de vida, el **ochenta y siete por ciento** de la incertidumbre de vida remanente es irreducible. La vida remanente, a primer orden, no está escrita en el presente — lo cual es una corrección sobria a bastante trabajo de prognosis. Pero al final de la vida se abre una brecha reducible de un factor cuatro. Ahí es donde un mejor pronóstico paga, y solo ahí.

Diapositiva 34 The determinability map: when does each approach win?

Un eje más, porque todo lo anterior vive en un único ajuste de calidad de sensor. Regeneramos la flota con ruido de sensor a la mitad, al uno, al doble y al cuádruple — misma semilla, mismos motores, mismos fallos, solo se mueve la calidad de medida — y volvimos a puntuar las dos familias ajustadas.

Tres hallazgos, de izquierda a derecha.

La prognosis es esencialmente inmune al ruido: el error de la IA es plano a lo largo de un factor ocho en ruido mientras que la extrapolación clásica se degrada un cuarenta por ciento. La ventaja **se ensancha** de 2,3 a 3,4 veces. O sea que el caso de negocio no depende de la calidad de los sensores.

El panel central es el que cierra el argumento de esta charla. Reducir a la mitad todas las sigmas de sensor — una mejora cara — deja el aislamiento confundible en 0,31 y 0,38. Ni de lejos el 0,92 que entregan sensores **distintos**. Dos firmas separadas 1,3 grados siguen separadas 1,3 grados por precisamente que las midas. Así que la orden de compra es específica: sondas en estaciones nuevas, no mejores sondas en las de siempre.

Y a la derecha, el detector clásico se cae por un precipicio — recall de 0,48 a cero — mientras que la IA se degrada con elegancia. La robustez frente a la calidad de instrumentación puede que sea la ventaja más transferible del aprendizaje aquí.

Diapositiva 35 What it is worth — and why it might be nothing*[recortable]*

Brevemente, cuánto vale, y este capítulo abre con sus propias reservas a propósito.

Monetizamos exactamente **un** mecanismo, el único que los resultados sostienen: una prognosis menos sesgada que convierte retiradas no programadas en programadas. Todo lo demás que un entusiasta podría contar se discute y se deja deliberadamente fuera del total.

Para un operador de cien motores, la mediana son tres millones de dólares al año. Pero hay que leer la dispersión, no la mediana: percentil diez, 0,9 millones; percentil noventa, 8 millones; y negativo neto en un uno por ciento de los sorteos.

Y la columna de la derecha es por qué podría no valer nada: el muro de aislamiento sigue en pie, así que un operador que espere mejor diagnóstico de esta inversión se llevaría un chasco; las falsas alarmas erosionan confianza y dinero; y la comprobación sim-to-real preservó el orden pero no necesariamente la magnitud.

7. Qué llevarse — diapositivas 36–40**4 min**

Diapositiva 37 The split verdict

Entonces, la respuesta a la pregunta con la que empezó la charla.

El aprendizaje gana donde la tarea es agregación estadística a lo largo del tiempo. Prognosis — 2,3 veces mejor que lo que hay hoy desplegado, y robusto entre tres arquitecturas y a lo largo de la calidad de sensor. Contra el mejor método clásico la ventaja es de 1,34 veces y solo tarde en la vida. Instante de detección. Incertidumbre calibrada, 1,34 veces cuando los dos lados se calibran igual.

Es una afirmación más estrecha que la que habría hecho hace dos semanas, y es más estrecha porque fuimos a buscar la debilidad de nuestros propios números de titular.

Nadie gana donde la tarea está limitada por lo que los sensores observaron. El aislamiento confundible es un empate, y el arreglo son setenta y siete puntos porcentuales que dan las sondas de estación reales, y exactamente cero de las virtuales.

[el reencuadre: esta es la idea de cierre] Y quiero tener cuidado con lo que eso dice sobre la física, porque es fácil malinterpretarlo. La física no perdió. Inyectar física dentro del modelo aprendido falló, dos veces. Pero la física **diagnosticó los límites**: la geometría de la matriz de influencia predijo, antes de que corriera ningún aprendizaje, exactamente dónde iba a fallar cada método — y acertó. Usar la física para saber qué es cognoscible funcionó completamente.

Diapositiva 38 What an engineering organization should do on Monday

Si os lleváis una sola diapositiva, llevaos esta. En orden de cuánto dinero mueve cada punto.

Desplegad aprendizaje para prognosis primero: ese es el caso de negocio. Detección: detección de cambios moderna con ventanas ajustadas; la victoria vino de buscar la ventana, que es barato y auditable, no de la profundidad de la red. Aislamiento: comprad sensores, no

modelos — y concretamente sondas en estaciones nuevas. Rediseñad el calendario de reportes antes de comprar nada. Proteged el parque de sensores: un termopar a la deriva corrompe a todos los consumidores aguas abajo, sean aprendidos o clásicos. Desconfiad de comparaciones sin ajustar en cualquiera de las dos direcciones. Y exigid pre-registro de las afirmaciones de vuestros proveedores.

[el último punto, con una pausa antes] Un veredicto partido es el aspecto que tiene una evaluación honesta. Si un proveedor os enseña un pleno, eso debería subir vuestra sospecha, no vuestra confianza.

Diapositiva 39 What transfers off this simulator — and what does not

Por último, la honestidad intelectual que este tipo de trabajo exige.

Lo que transfiere fuera de un simulador son órdenes, mecanismos y geometría: qué método gana dónde y por qué, y la estructura de observabilidad que comparte cualquier motor de esta clase. Todas las afirmaciones operativas que he hecho son de ese tipo.

Lo que **no** transfiere son los números absolutos. Un error de 858 ciclos es una propiedad de este mundo simulado y de sus ajustes de ruido. No estoy afirmando que vuestra flota vaya a ver eso.

Y toda la base de evidencia se regenera en unos once minutos en un solo ordenador de escritorio. Cada figura de estas diapositivas salió de un script; ninguna se copió a mano.

Diapositiva 40 The split verdict is the result

[pausa. Deja la diapositiva dos segundos antes de hablar.]

El veredicto partido es el resultado. Una comparación de métodos que produce un pleno normalmente está midiendo esfuerzo, no método.

Gracias. Encantado de responder preguntas.

Preparación de preguntas

Las objeciones probables, con respuesta honesta. No te marques un farol: todas tienen respuesta real dentro del trabajo.

«Vuestra línea base tradicional es una recta. Eso es un hombre de paja.»

Es justo, y lo comprobamos. La extrapolación lineal es lo que las aerolíneas usan de verdad, así que es la línea base correcta para una afirmación de transferencia a la industria; pero no es la frontera de la investigación. Así que implementamos un pronóstico basado en similitud, el método clásico estándar en C-MAPSS, que sí puede seguir una degradación no lineal. Reduce casi a la mitad el error clásico: de 1981 a 1118. La IA sigue ganando con 858. Así que la afirmación honesta tiene dos escalas: 2,3 veces mejor que lo que los operadores tienen hoy desplegado, y 1,34 veces mejor que el mejor método clásico. Una ventaja del treinta y cuatro por ciento, no un orden de magnitud. Y ni siquiera eso en todas partes: al setenta por ciento de la vida los dos empatan. La ventaja del aprendizaje es de vida tardía.

«Es todo sintético. ¿Por qué debería creerme nada?»

Cuatro defensas, todas construidas antes de los experimentos titulares. El generador está anclado a medidas certificadas a las que nunca se ajustó. El dataset tuvo que pasar un umbral de dificultad que falló dos veces y forzó rediseños. La conclusión central se volvió a probar sobre un banco de pruebas que no generamos nosotros. Y decimos explícitamente que los números absolutos no transfieren: solo transfieren órdenes, mecanismos y geometría.

«Veinte motores de test. Trece episodios confundibles. Eso no es nada.»

Correcto, y es nuestra principal limitación estadística. Es la razón de que cada test esté emparejado por motor, de que usemos tests exactos en lugar de asintóticos, y de que reportemos tamaños de efecto e intervalos bootstrap en vez de solo p-valores. Es también la razón de que una de nuestras propias hipótesis del eje de ruido quedara refutada sobre un umbral más fino de lo que la muestra podía resolver — y lo reportamos en lugar de esconderlo.

«Habéis refutado vuestras propias hipótesis. ¿No es eso un proyecto fallido?»

Al contrario. El pre-registro es lo que hace creíble una refutación, y las refutaciones son los resultados que cambiaron nuestras recomendaciones. H2 convirtió una pregunta de software en una pregunta de compras. H4 mató una técnica popular en esta tarea, dos veces. Un estudio que confirma todo lo que predijo suele ser un estudio que movió los postes de la portería.

«¿Por qué no una arquitectura moderna grande?»

Comprobamos que el resultado no es un artefacto de la arquitectura: una red convolucional temporal y un Transformer baten a la línea base clásica esencialmente por el mismo margen que el modelo recurrente. La elección de arquitectura apenas importa aquí, y las redes más grandes no ayudaron: el techo es la información que hay en las medidas, no el tamaño del modelo.

«¿Funcionaría esto en un motor del que no tenéis datos?»

La receta sí. El gemelo se construye únicamente a partir de una hoja de certificado de tipo y de una base de datos pública de emisiones, y las dos existen para todo motor certificado. Eso es deliberado: el método es portable aunque nuestros números concretos no lo sean.

«¿Cuál es la aportación más novedosa?»

El certificado, en la diapositiva 32. Análisis de observabilidad hay; una garantía de identificabilidad por motor y resuelta por su historia que además esté **demostrada honesta contra el estado verdadero de los componentes** no la hay, porque en hardware real esa comprobación es imposible. Es la única aportación que necesitaba que existiera todo este banco de pruebas.